

ใบงานการทดลอง (Lab Assignment)

หัวข้อ: การประเมินประสิทธิภาพโมเดล Classification ด้วย ROC Curve, AUC และ Evaluation Metrics

วิชา: Machine Learning

วัตถุประสงค์ของการทดลอง

1. เพื่อฝึกการเตรียมข้อมูลและการทำ K-fold Cross Validation ตามกระบวนการ Machine Learning Workflow
2. เพื่อเข้าใจหลักการทำงานและการคำนวณ Confusion Matrix, Sensitivity (TPR) และ False Positive Rate (FPR)
3. เพื่อฝึกการสร้างและวิเคราะห์เส้นกราฟ ROC (Receiver Operating Characteristic) และค่า AUC (Area Under the Curve)
4. เพื่อฝึกการเปรียบเทียบประสิทธิภาพระหว่างโมเดล (เช่น Logistic Regression vs Ridge Classifier)

โจทย์สถานการณ์ (Scenario)

โรงพยาบาลแห่งหนึ่งต้องการสร้างโมเดล Machine Learning เพื่อพยากรณ์ภาวะเสี่ยงต่อการเป็น "โรคอ้วน/โรคเบาหวาน" (Obesity/Diabetes Prediction) จากข้อมูลดัชนีทางกายภาพของผู้ป่วย เช่น Weight, BMI, Blood Pressure และ Glucose Level (จำแนกแบบ Binary Classification: 1 = เป็นโรค , 0 = ไม่เป็นโรค)

ให้นักศึกษาสร้างและประเมินโมเดลตามขั้นตอนต่อไปนี้:

ขั้นตอนการทดลอง (Lab Steps)

Step 1: Data Preparation & Preprocessing

1. โหลด Dataset (สามารถใช้ Synthetic Dataset จาก `make_classification` หรือ Dataset การแพทย์ เช่น Diabetes Dataset)
2. ตรวจสอบและทำ Data Cleaning (จัดการ Missing Values ตามหลักการลบ Row ข้อมูลที่ขาดหาย)
3. แบ่งข้อมูลออกเป็น Training Set, Validation Set และ Test Set หรือใช้ K-Fold Cross Validation ($K = 5$ หรือ $K = 10$)

Step 2: Model Training & Evaluation

1. เทรนโมเดลจำแนกประเภทอย่างน้อย 2 โมเดล ได้แก่:
 - Logistic Regression (โมเดลที่ส่งผลลัพธ์เป็น Probability)
 - Ridge Classifier หรือ Decision Tree/Random Forest
2. คำนวณค่า Confusion Matrix ที่ Decision Threshold เริ่มต้น (0.5)
3. คำนวณค่า Evaluation Metrics ต่อไปนี้:

- **Sensitivity / True Positive Rate (TPR):** $TPR = \frac{TP}{TP+FN}$
- **Specificity:** $Specificity = \frac{TN}{TN+FP}$
- **False Positive Rate (FPR):** $FPR = 1 - Specificity = \frac{FP}{FP+TN}$
- **Precision & Accuracy**

Step 3: ROC Curve & AUC Analysis

1. เปลี่ยนค่า Decision Threshold ในช่วง 0.0 ถึง 1.0 เพื่อหาจุด座標 (FPR, TPR) ต่างๆ
2. พล็อตเส้น **ROC Curve** โดยให้แกน X เป็น FPR ($1 - Specificity$) และแกน Y เป็น TPR (Sensitivity)
3. คำนวณพื้นที่ใต้กราฟ **AUC (Area Under the Curve)** ของแต่ละโมเดล
4. พล็อตเปรียบเทียบ ROC Curve ของทั้งสองโมเดลลงบนกราฟเดียวกัน พร้อมแสดงเส้น Diagonal Line ($AUC = 0.5$)



โครงสร้างโค้ดตัวอย่าง (Scaffold Python Code)

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import make_classification
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import confusion_matrix, roc_curve, auc, classification_report

# 1. Generate Synthetic Classification Dataset
X, y = make_classification(n_samples=1000, n_features=10, n_informative=8,
                          n_classes=2, weights=[0.6, 0.4], random_state=42)

# 2. Split Data into Train and Test Sets
X_train, X_test, y_train, y_test = train_test_split(X, y, test_split_size=0.3, ra

# 3. Model Training
model_lr = LogisticRegression()
model_rf = RandomForestClassifier(random_state=42)

model_lr.fit(X_train, y_train)
model_rf.fit(X_train, y_train)

# 4. Predict Probabilities for ROC
y_pred_proba_lr = model_lr.predict_proba(X_test)[: , 1]
y_pred_proba_rf = model_rf.predict_proba(X_test)[: , 1]

# 5. Calculate ROC curve and AUC
fpr_lr, tpr_lr, thresholds_lr = roc_curve(y_test, y_pred_proba_lr)
```

```

roc_auc_lr = auc(fpr_lr, tpr_lr)

fpr_rf, tpr_rf, thresholds_rf = roc_curve(y_test, y_pred_proba_rf)
roc_auc_rf = auc(fpr_rf, tpr_rf)

# 6. Plot ROC Curve
plt.figure(figsize=(8, 6))
plt.plot(fpr_lr, tpr_lr, color='blue', lw=2, label=f'Logistic Regression (AUC = {
plt.plot(fpr_rf, tpr_rf, color='green', lw=2, label=f'Random Forest (AUC = {roc_a
plt.plot([0, 1], [0, 1], color='gray', linestyle='--', label='Random Guessing (AU

plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate (1 - Specificity)')
plt.ylabel('True Positive Rate (Sensitivity)')
plt.title('Receiver Operating Characteristic (ROC) Curve')
plt.legend(loc="lower right")
plt.grid(True)
plt.show()

```

? คำถามประเมินความเข้าใจ (Discussion & Questions)

ให้นักศึกษาตอบคำถามต่อไปนี้ลงในรายงานสรุปผลการทดลอง:

1. การเลือก **Decision Threshold**: หากโจทย์นี้เป็นระบบคัดกรองทางการแพทย์ที่ต้องการให้หลุดตรวจพบผู้ป่วยน้อยที่สุด (เน้น Sensitivity สูง) เราควรปรับ Decision Threshold ให้สูงขึ้นหรือต่ำลง? และส่งผลต่อค่า FPR อย่างไร?
2. ความหมายของค่า **AUC**: ถ้าโมเดล A มีค่า $AUC = 0.88$ และโมเดล B มีค่า $AUC = 0.62$ โมเดลใดมีความสามารถในการแยกแยะ Class (Separation Power) ดีกว่ากัน เพราะเหตุใด?
3. กรณี **AUC ต่ำกว่า 0.5**: หากพล็อต ROC Curve แล้วได้ค่า $AUC < 0.5$ หมายความว่าอย่างไร และเกิดจากสาเหตุใดได้บ้าง?
4. ความแตกต่างของ **ROC Curve** ในโมเดลที่ให้ **Probabilities vs Non-Probabilities**: ทำไมโมเดลที่ผลลัพธ์ไม่เป็น Probability (เช่น Decision Tree ทัวไป หรือ Non-probabilistic Classifier) จึงได้ ROC Curve ที่ลักษณะเป็นเหลี่ยมดกมากกว่าเส้นโค้งเรียบ?