

Lab 2 วิชา การเรียนรู้ของเครื่องกล (Machine Learning)

หัวข้อ

1. Decision Tree Classifier
2. Decision Tree Regressor

คำสั่งส่วนที่ 1

1. เลือกใช้ Decision Tree Classifier หรือ Decision Tree Regressor กับข้อมูลไวน์ (load_wine) ให้เหมาะสม
 - a. ทำความรู้จักกับชุดข้อมูล load_wine และเติมคำตอบลงในใบงานส่วนที่ 1
 - b. แยกข้อมูล Train 80% และ Test 20% (ใช้คำสั่ง train_test_split หรือแยกเองก็ได้)
 - c. หาค่าความสูงจำกัดของต้นไม้ที่เหมาะสม โดยบันทึกผลลงในใบงานส่วนที่ 2
 - d. แสดงผลต้นไม้ บันทึก และวางภาพลงในใบงานส่วนที่ 3
 - e. Train โดยใช้ข้อมูลที่แยกไว้สำหรับ Train และทำการพยากรณ์ข้อมูลโดยใช้ข้อมูลที่แยกไว้สำหรับ Test
 - f. บันทึกสรุปผลการพยากรณ์ทั้งหมดลงในใบงานส่วนที่ 4
2. ***ไม่บังคับ*** ใช้ Decision Tree Classifier หรือ Decision Tree Regressor กับข้อมูลที่สืบค้นไว้ตัวใดก็ได้ โดยเลือกมา 1 ชุดข้อมูล
 - a. ทำความรู้จักกับชุดข้อมูลที่กลุ่มของตนเองเลือกมา พยายามหาคำตอบของทุกคำถามในใบงานส่วนที่ 1 (อาจมีประโยชน์ในอนาคต)
 - b. แยกข้อมูล Train 80% และ Test 20% (ใช้คำสั่ง train_test_split หรือแยกเองก็ได้)
 - c. หาค่าความสูงจำกัดของต้นไม้ที่เหมาะสม พยายามหาคำตอบของทุกคำถามในใบงาน
 - d. แสดงผลต้นไม้
 - e. Train โดยใช้ข้อมูลที่แยกไว้สำหรับ Train และทำการพยากรณ์ข้อมูลโดยใช้ข้อมูลที่แยกไว้สำหรับ Test
 - f. อาจบันทึกสรุปผลการพยากรณ์ทั้งหมดไว้
3. ส่งงานผ่านระบบ Microsoft Teams

ใบงานส่วนที่ 1 ทำความรู้จักกับชุดข้อมูล

ชุดข้อมูล load_wine..... มีข้อมูลบรรจุอยู่จำนวน	178..... Samples
Target ของชุดข้อมูลนี้มี	3..... Class
Target แต่ละประเภท มีข้อมูลกี่ Samples	ประเภท class_0..... มีข้อมูล59..... Samples ประเภท1..... มีข้อมูล71..... Samples ประเภท ...2..... มีข้อมูล48..... Samples ... (คัดลอกและวางต่อไปจนกว่าจะเพียงพอ)
มิติของข้อมูล (จำนวน Feature)	13..... Features
ระบุนามชื่อของ Feature ทั้งหมด	['alcohol', 'malic_acid', 'ash', 'alcalinity_of_ash', 'magnesium', 'total_phenols', 'flavanoids', 'nonflavanoid_phenols', 'proanthocyanins', 'color_intensity', 'hue', 'od280/od315_of_diluted_wines', 'proline']
ข้อมูล Target (ที่ต้องการพยากรณ์) เป็นข้อมูลแบบ... (เลือก 1 ข้อ)	ต่อเนื่อง (Continuous) / ไม่ต่อเนื่อง (Discrete)
นักศึกษาเลือกใช้	Decision Tree Classifier / Decision Tree Regressor
ใช้คำสั่ง Print และคัดลอกชุดข้อมูล load_wine..... ที่เป็น data ทั้งหมดแล้ววางลงในช่องนี้ >>>>	<pre>[1.423e+01 1.710e+00 2.430e+00 ... 1.040e+00 3.920e+00 1.065e+03] [1.320e+01 1.780e+00 2.140e+00 ... 1.050e+00 3.400e+00 1.050e+03] [1.316e+01 2.360e+00 2.670e+00 ... 1.030e+00 3.170e+00 1.185e+03] ... [1.327e+01 4.280e+00 2.260e+00 ... 5.900e-01 1.560e+00 8.350e+02] [1.317e+01 2.590e+00 2.370e+00 ... 6.000e-01 1.620e+00 8.400e+02] [1.413e+01 4.100e+00 2.740e+00 ... 6.100e-01 1.600e+00 5.600e+02]]</pre>
ใช้คำสั่ง Print และคัดลอกชุดข้อมูล load_wine..... ที่เป็น Target ทั้งหมดแล้ววางลงในช่องนี้ >>>>	<pre>[0 1 2 2]</pre>

ในงานส่วนที่ 2 หาค่าความลึกที่ลึกที่สุด (ความลึกจำกัด; max depth) ที่เหมาะสม


(เนื่องจากโจทย์ข้อนี้มีจำนวนคลาสมากกว่า 2 คลาส (คลาส = ประเภท) ดังนั้นการหาค่า TP, TN, FP และ FN จึงมีความซับซ้อนกว่าแบบ 2 คลาส โดยจำเป็นต้องเปลี่ยนวิธีการคำนวณ Average ใหม่ ปัญหาต่อมาก็คือ ควรใช้วิธีการ Average แบบไหนจึงจะเหมาะสม)

max_dept h	Accuracy	Precision	Recall	F1-score
1	0.6388888888888888	0.5061728395061729	0.5208333333333333	0.4676422764227642
2	0.4676422764227642	0.8289473684210527	0.8541666666666666	0.8085425685425686
3	0.9722222222222222	0.9777777777777777	0.9791666666666666	0.9777530589543938
4	0.9722222222222222	0.9777777777777777	0.9791666666666666	0.9777530589543938
5	0.9722222222222222	0.9777777777777777	0.9791666666666666	0.9777530589543938
10	0.9722222222222222	0.9777777777777777	0.9791666666666666	0.9777530589543938
100	0.9722222222222222	0.9777777777777777	0.9791666666666666	0.9777530589543938
1000	0.9722222222222222	0.9777777777777777	0.9791666666666666	0.9777530589543938

ใบงานส่วนที่ 3 รูปร่างของต้นไม้

จงวางภาพโครงสร้างของต้นไม้ที่บันทึกได้จากการฝึกฝนด้วยข้อมูล.....load_wine.....

*ใช้คำสั่ง `plot_tree` จาก `library sklearn` ได้เลย



โค้ดที่ใช้ในการทดลอง (ระบุโค้ดภาษา Python ที่นี้)

```
from sklearn import tree
from sklearn.datasets import load_wine
import pandas as pd
data = load_wine()

X = data.data
Y = data.target
print(X)
print(Y)
print(data.target_names)

print(data.target_names)

import numpy as np

classes, count = np.unique(data.target, return_counts=True)
for c, cu in zip(classes, count):
    print(c, cu);

print(data.feature_names)

from sklearn.model_selection import train_test_split
from sklearn import tree

X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.20, train_size=0.80, random_state=0)

model = tree.DecisionTreeClassifier(max_depth=1)

model = model.fit(X_train, Y_train)

X_predic = model.predict(X_test)

model = tree.DecisionTreeClassifier(max_depth=1)

model.fit(X_train, Y_train)

X_predic = model.predict(X_test)
```

```

from sklearn.metrics import precision_score

scores = model.score(X_test, Y_test)
print(scores)

from sklearn.metrics import precision_score

precision = precision_score(Y_test, X_predic, average='macro')
print(precision)

from sklearn.metrics import recall_score

recall = recall_score(Y_test, X_predic, average='macro')
print(recall)

from sklearn.metrics import f1_score

f1 = f1_score(Y_test, X_predic, average='macro')
print(f1)

from sklearn import tree

tree.plot_tree(model)

max_d = [1,2,3,4,5,10,100,1000]
for i in max_d:
    X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.20, train_size=0.80, random_state=0)

    model = tree.DecisionTreeClassifier(max_depth=i)

    model = model.fit(X_train, Y_train)

    X_predic = model.predict(X_test)

    scores = model.score(X_test, Y_test)
    print(f"i = {i} Acc = {scores}")

    precision = precision_score(Y_test, X_predic, average='macro')
    print(f"i = {i} precision = {precision}")

    recall = recall_score(Y_test, X_predic, average='macro')

```

```
print("i = {i} recall = {recall}")

f1 = f1_score(Y_test, X_predic, average='macro')
print("i = {i} f1 = {f1}")
```

ใบงานส่วนที่ 4 สรุปผลการทดลอง

จงเขียน Confusion Matrix ของผลการทดลองที่ดีที่สุด โดยระบุว่าเลือก max_depth เท่ากับเท่าไร ระบุ Accuracy, Precision, Recall และ F1-score ลงในพื้นที่ย่างนี้ (เนื่องจากโจทย์ข้อนี้มีจำนวนคลาสมากกว่า 2 คลาส (คลาส = ประเภท) ดังนั้นการหาค่า TP, TN, FP และ FN จึงมีความซับซ้อนกว่าแบบ 2 คลาส โดยจำเป็นต้องเปลี่ยนวิธีการคำนวณ Average ใหม่ ปัญหาต่อมาก็คือ ควรใช้วิธีการ Average แบบไหนจึงจะเหมาะสม)

```
การใช้ average macro ใช้ maxdepth = 3 acc = 0.9722222222222222
precision = 0.9777777777777779
recall = 0.9791666666666666
f1 = 0.9777530589543938
```